

基于深度学习的语音情感识别系统研究与实现

研究报告

学生姓名：张明化

学号：S001

研究主题：语音情感识别

质量等级：优秀

2024年04月29日

摘要

本研究针对语音情感识别任务，提出了一种基于多尺度时频注意力机制的深度学习模型（MS-TFAN）。该模型融合卷积神经网络（CNN）的局部特征提取能力和长短期记忆网络（LSTM）的时序建模优势，并引入注意力机制自动聚焦于情感相关的关键帧。实验在IEMOCAP和RAVDESS两个公开数据集上进行，结果表明本方法在加权准确率（WA）和非加权准确率（UA）上分别达到78.3%和76.8%，显著优于传统MFCC+SVM基线方法和现有深度学习方法。此外，本研究还探索了跨语言情感迁移学习，验证了模型在低资源语言情感识别中的有效性。

关键词：语音情感识别、MFCC、CNN-LSTM、注意力机制、IEMOCAP

一、文献综述

语音情感识别（Speech Emotion Recognition, SER）是情感计算领域的重要研究方向。根据特征提取方式的不同，现有方法可分为基于手工特征的传统方法和基于深度学习的端到端方法两大类。Schuller等人系统比较了韵律特征、谱特征和音质特征在情感识别中的效果，发现MFCC结合支持向量机可以达到较好的分类性能。然而，传统方法存在手工特征难以捕捉复杂情感语义信息、泛化能力有限的局限。Han等人首次将CNN应用于语音情感识别，利用时频图作为输入，在IEMOCAP数据集上取得了62.1%的准确率。Satt等人提出了CNN-LSTM混合架构，利用LSTM建模语音的时序依赖关系，准确率提升至68.5%。Chen等人引入注意力机制，使模型能够自动关注情感表达的关键片段，进一步将准确率提升至71.2%。Zhang等人提出了基于迁移学习的跨语言情感识别框架，仅需10%的目标语言标注数据即可达到全监督训练90%的性能。综合文献分析，现有方法存在以下不足：多数方法仅使用单一尺度的特征表示，难以同时捕捉细粒度的频谱细节和全局的时序模式；注意力机制的设计未充分考虑语音信号的多尺度特性。

二、研究方法

本研究提出的多尺度时频注意力网络（MS-TFAN）由四个核心模块组成：（1）多尺度特征提取模块，包含细粒度频谱特征（Mel频谱图+3层CNN）、时序统计特征（MFCC+1D-CNN）和韵律特征（基频F0+BiLSTM）三个分支；（2）时序建模模块，采用双向LSTM网络，隐藏层维度128，层数2；（3）多尺度注意力机制，同时建模时间和频率两个维度的注意力；（4）情感分类模块，全连接层配置为256→128→64→N_classes，采用标签平滑（ $\epsilon=0.1$ ）。训练策略：AdamW优化器（weight decay=0.01），初始学习率0.001，Cosine退火调度，Batch size 32，数据增强采用SpecAugment、时间拉伸和音高偏移。

三、实验设计与结果分析

实验在IEMOCAP和RAVDESS两个数据集上进行。IEMOCAP包含12小时、10,039条语音片段，10名说话人，6种情感标签。采用加权准确率（WA）、非加权准确率（UA）和F1-score作为评估指标。主要结果：MFCC+SVM基线WA=58.3%，CNN WA=62.1%，CNN-LSTM WA=68.5%，Attention-LSTM WA=71.2%，MS-TFAN WA=78.3%。消融实验表明注意力机制贡献最大（+7.5%），时序建模贡献5.8%，多尺度特征贡献4.2%。跨语言迁移实验表明，使用10%中文标注数据微调即可达到全监督训练94.7%的性能。

四、总结与展望

本研究提出了多尺度时频注意力网络（MS-TFAN），在IEMOCAP数据集上取得了78.3%的加权准确率和76.8%的非加权准确率。主要贡献包括多尺度特征融合、时频注意力机制和跨语言迁移学习。研究局限包括实验主要在表演型数据集上进行、语言覆盖有限、计算复杂度较高。未来可探索多模态融合、轻量化部署和情感强度估计。